

LFA-Net 复现与几何感知血管分割优化

Retinal Vasculature Segmentation
based on Deep Learning

第15组

组员：徐凯威 王子腾 杜伟悦 梁欣宇

研究背景与临床意义

- 临床应用价值


- 无创观测窗口：视网膜血管是人体唯一可无创直接观测的微血管系统。
- 疾病生物标志物：血管的迂曲、扩张、微血管瘤等形态改变，辅助诊断糖尿病视网膜病变（DR）、高血压、青光眼及动脉硬化。

- 当前痛点与需求

- 人工标注局限：专家手动分割单张图像平均耗时**20分钟**，且存在主观差异，无法满足大规模筛查需求。
- 自动化挑战：现有算法在病灶干扰下鲁棒性不足，对末端微血管的分割精度仍有提升空间。

- 研究目标

- 开发高精度、全自动的分割算法，辅助医生进行快速筛查与量化分析。





任务定义与核心挑战

- 任务描述

- 输入彩色眼底图像，输出像素级二值掩膜（1=血管，0=背景）。

- 三大技术难点

- 1. 多尺度特征差异：主血管宽度可达**10-15**像素，而末端毛细血管仅**1-2**像素，极易在下采样中丢失。
 - 2. 低对比度与噪声：微血管与视网膜背景灰度值接近，边界模糊不清。
 - 3. 强干扰项（假阳性来源）：
 - 病灶干扰：出血点、硬性渗出物在灰度上与血管相似。
 - 视盘干扰：视盘区域高亮且边界复杂，易被误判为血管。



基准模型：LFA-Net (LiteFusion Attention Network)


• 模型特性

- **LiteFusion-Attention** (瓶颈)：融合全局/局部上下文 + 调制注意力 + token/channel mixing + 残差，增强长距离依赖。
- **RAA 跳连增强**：Region-Aware Attention 在 skip 前抑制背景噪声、强化血管区域细节。
- 部署友好：约 0.11M 参数、0.42MB、4.46 GFLOPs。


• 局限性分析

- 细血管易断裂/漏检（低对比度末端结构不稳定）。
- 视盘（OD）附近易混淆（高亮 + 血管汇聚 → 假阳性）。
- 轻量化表达上限：对复杂背景/病变更依赖增强与损失设计，训练轮次不足时收敛偏慢。

- 评价指标：Jaccard(IoU)、F1-score、Sensitivity(Recall)、Specificity、Precision



LFA-Net 结构概览



- **Encoder:** $1 \times 1/3 \times 3$ 空洞 3×3 并行多尺度
- **Skip:** RAA 精选跳连
- **Bottleneck:** LiteFusion-Attention




数据集与预处理策略

数据集

- **DRIVE**: 40张 (20训练/20测试), 分辨率 565×584 , 提供金标准掩膜, 常用于基准测试。
- **STARE**: 20张, 分辨率 700×605 , 包含大量病变样本, 用于验证泛化能力。
- **CHASE_DB**: 28 张 (20 训练 / 8 测试), 分辨率 1024×1024 , 用于评估模型在高分辨率与细小血管场景下的分割能力。

精细化预处理流程

1. 绿色通道提取: 基于光学特性, 绿色通道下血管吸收率最高, 纹理对比度最强。
2. 对比度增强: 采用 **CLAHE** (限制对比度自适应直方图均衡化) 提升局部细节, 结合 **Gamma** 校正平衡光照。
3. 数据扩增策略:
 - 几何变换: 随机旋转、翻转。
 - 弹性形变: 模拟眼球曲率变化, 增加训练样本多样性, 防止过拟合。




Baseline 复现结果 (DRIVE)

指标 (DRIVE test)	
IoU (Jaccard)	0.6342
F1 / Dice	0.7759
Recall (Sens.)	0.7595
Precision	0.7982
Specificity	0.9814
Accuracy	0.9619



- 整体平衡性不错，但与论文仍有差距：
主要受限于数据量/训练轮次
- 典型问题：视盘附近易误判（假阳性），
细小血管末端易断裂

可视化（从左到右一般为：原图 / 视盘或ROI / GT / 预测 / 误差图；误差图常用：绿=TP，红=FN，蓝=FP）



改进一：引入视盘 (OD) 先验

- 动机：OD 区域高亮且血管汇聚，加入 OD 位置先验期望减少视盘边界假阳性
- 做法：用 SegFormer 生成 OD Mask，与 RGB 拼接 → 输入变为 4 通道 (B,4,H,W)
- 结果：指标小幅下降 (IoU 0.6342 → 0.6240) ， 没有达到预期

DRIVE 指标对比

Baseline: IoU 0.6342 | Recall 0.7595 | Prec 0.7982

+OD Mask 输入: IoU 0.6240 | Recall 0.7490 | Prec 0.7945

失败原因

1. OD Mask 自动生成存在噪声，硬拼接等价于把噪声先验喂给网络
2. 语义混淆：OD 区域内部确实有粗血管，Mask 让网络更难区分“抑制背景 vs 保留血管”
3. 简单拼接在深层被稀释，不能形成有效的空间引导

改进二：隐式几何感知 —— 损失函数 + 结构改进

- 核心思路：不再硬注入 OD 先验，而是让模型在训练目标与算子结构上“更关注血管形态”
- 损失函数：
 - Focal Tversky (处理类别不平衡、抑制 FP/FN 可调)
 - Boundary Loss (强化血管边缘与细结构)
 - 权重 1.0:0.1
- 结构变体：
 - 变体A: DCN + Strip Pooling (适配弯曲细长形状、长程依赖)
 - 变体B: ASPP + CBAM (多尺度 + 通道注意)

联合损失

$$L_{total} = \lambda_1 L_{FocalTversky}(\alpha = 0.7, \beta = 0.3, \gamma = 0.75) + \lambda_2 L_{Boundary}$$

直观：更严惩假阳性 (α 高) $\rightarrow$ 背景更干净，但可能牺牲召回

预期效果

- 减少背景噪声 (**Precision** $\uparrow$ / **Specificity** $\uparrow$)
- 边界更锐利、断裂更少
- 多尺度/形变卷积更匹配血管几何


实验结果对比分析

训练 100 轮后的测试集表现：

Configuration	IoU	F1	Recall	Precision	Spec.
Baseline	0.6342	0.7759	0.7595	0.7982	0.9814
New Loss Only	0.6119	0.7581	0.6812	0.8654	0.9897
Loss + ASPP	0.6120	0.7587	0.6790	0.8665	0.9899
Loss + DCN	0.6077	0.7550	0.6799	0.8579	0.9891

- **Precision:** 0.798 → 0.866（显著提升）
- **Specificity:** 提升到 ~0.99，背景误判明显减少
- 代价：Recall 从 0.76 降到 ~0.68 → 模型更“保守”，细小血管可能被漏掉
- 结构层面：
 - **ASPP** 版本在小样本下更稳健；
 - **DCN** 引入偏移学习，可能更易过拟合


实验结果对比分析



DRIVE



STARE




CHASE_DB

train/valid loss: 三数据集在 200 epoch 内总体稳定收敛

STARE 的 valid loss 波动更大 (样本差异更强), 提示需要更强正则/更合适的损失权重

定性结果



DRIVE

STARE

CHASE_DB

总结 & 展望

结论

- 1) 复现 LFA-Net: baseline 在 DRIVE 上达到 IoU 0.634
- 2) OD 先验硬融合无效: 噪声/语义混淆/深层稀释
- 3) 几何感知优化: Precision/Spec 明显 $\uparrow$, 但 Recall $\downarrow$

未来工作

- 显式拓扑约束: cIDice / centerline loss, 减少断裂
- 更稳健的 OD 融合: 作为注意力引导/门控而非硬输入
- 补齐跨数据集指标与消融: 结构、损失、增强的贡献拆分



感谢聆听

第15组

组员：徐凯威 王子腾 杜伟悦 梁欣宇
